

Diffusion Transformer를 이용한 해빙 농도 변화 추세 예측 모델

정예준^{0,1*}, 김동윤^{0,1*}, 박진선^{1,2}

¹부산대학교 정보컴퓨터공학부

²부산대학교 Digital-X AIoT 연구센터

{ yejun2, dongyoon0201, jspark }@pusan.ac.kr

요 약

해빙 농도(Sea Ice Concentration, SIC) 예측은 기후 변화 감시와 극지 해양 활동을 위해 높은 정확도가 요구되는 과업이다. 기존 SIC 예측 연구들은 특정 시간 간격 이후 단일 시점을 예측하는 문제로 접근하였다. 이러한 접근은 연속적인 움직임을 가지는 해빙 농도에 대한 움직임을 정확하게 포착하지 못하며, 급격한 변화가 발생하는 여름철과 같은 상황에 예측 성능이 매우 떨어진다는 한계가 존재한다. 본 연구에서는 하루 단위로 관측된 해빙 농도 지도를 개별 프레임으로 정의하고, 전 기간에 걸친 해빙 농도의 변화를 프레임간 시간적 연속성이 존재하는 영상 데이터로 재해석한다. 이를 바탕으로 적응형 계층 정규화를 통한 환경 정보 주입을 결합하여, 환경적 요소를 고려한 일별 해빙 농도 생성 프레임워크를 제안한다. 실험 결과, 날짜 별 연속 예측 관점에서 모델이 시간적 일관성을 유지하면서 해빙의 자연스러운 변화 패턴을 효과적으로 재현함을 확인하였다. 이는 SIC 예측을 정적 회귀 문제가 아닌 생성 문제로 접근함으로써, 해빙 예측 분야에서 생성 모델의 활용 가능성을 제시한다는 점에서 의의가 있다.

1. 서론

해빙 농도(Sea Ice Concentration, SIC)는 극지방의 기후 변화 양상을 분석하는 데 있어 핵심 지표로 활용되며, 해양 순환, 생태계 변화, 극지 항로 운영 등 다양한 분야와 밀접한 관련을 가진다[1]. 최근 기후 변화의 가속화로 인한 해빙 변화의 불규칙성이 크게 증가하고 있어, 해빙 상태를 정밀하게 예측하는 문제의 중요성이 점차 강조되고 있다.

기존의 해빙 농도 예측 연구들은 특정 시간 간격 이후의 해빙 상태를 예측하는 방식으로 진행되어 왔다. 최근에는 U-Net 방식 중심의 딥러닝 모델들이[2] 도입되어, 특정 시간 간격 이후의 해빙 농도를 비교적 안정적으로 예측하는 성과를 보이고 있다[3]. 그러나 기존 모델들은 수개월 이후 특정 달의 평균적인 상태를 예측하는 데에는 효과적이었으나, 예측 시점을 서로 독립적인 단일 시점으로 가정함으로써 시간적으로 연속적인 해빙 변화 과정을 충분히 반영하지 못하는 한계를 가진다[4].

실제 해빙의 다음 변화는 이전 시점의 상태와 환경 변수와 같은 여러 외부 환경의 영향으로 변화한다. 특히, 해빙 경계 부근에서 단기간 내 기상 조건과 해양 환경의 변화에 따라 급격히

변동하는 경우가 빈번하다[4]. 기존의 연구는 월 단위 예측 과정을 통해 급격한 변동에 따른 예측에 취약점이 존재하였고, 이전 상태를 순차적으로 생성하는 것이 아닌 단일 시점을 예측하는 과정으로 인해 빙하의 연속적인 움직임을 포착하지 못하는 한계를 가졌다. 빙하의 연속적인 변화 양상은 개별 예측 방식이 아닌 순차적 예측 방식을 통해 더욱 효과적으로 예측 가능하다.

본 연구에서는 위성 기반 해빙 농도의 시간적 변화를 프레임 간 의존성을 갖는 연속적인 영상 데이터로 해석하고, 미래 해빙 상태를 날짜 별로 순차적으로 생성하는 새로운 예측 프레임워크를 제안한다. 해당 방법은 이전 시점의 해빙 상태와 기후 정보를 누적하여 다음 시점의 상태를 생성함으로써, 복잡한 시공간 패턴과 비 선형적인 변화 패턴을 효과적으로 표현하는 것을 목표로 한다.

2. 방법론

본 연구에서는 Diffusion 기반 생성 모델을 활용하여 미래 해빙 농도 상태를 순차적으로 생성하는 예측 프레임워크를 제안한다. 그림 1은 각 시점의 해빙 농도 영상을 단일 이미지 생성 문제로 정의하고, 가우시안 분포의 잡음이 주입된 상태에서

* Equal Contribution




그림 1. 동영상 생성 방식을 통한 해빙 농도 예측 프레임워크

해당 잡음을 제거하는 과정을 학습함으로써 미래 상태를 생성하는 구조를 나타낸다.

잡음 예측 과정에서 이전 30일 동안의 해빙 농도 상태와 기후 정보를 조건 정보로 활용하여, 시간에 따라 누적되는 해빙 변화 흐름과 환경적 맥락을 반영할 수 있도록 한다. 잡음 제거를 위한 예측기는 Transformer 기반 구조로 구성되며, 해빙 분포 전반에 걸친 장거리 공간 의존성과 시공간적 상관관계를 효과적으로 학습한다. 자기회귀 생성 과정에서 편향과 오차 누적 문제 개선을 위하여, 자기회귀 생성 결과를 기반으로 추가적인 미세 조정 과정을 통해 장기 예측 안정성을 향상한다.

표현은 잡음 예측기로 동작하는 Diffusion Transformer (DiT) 구조의 입력으로 사용된다[8]. 이러한 구성은 국지적인 연산에 의존하는 기존 구조와 달리, 해빙 분포 전반에 걸친 장거리 공간 의존성을 충분히 고려할 수 있도록 한다. 결과적으로 본 연구에서 제안한 방식은 해빙 농도를 단일 값 예측 대상으로 취급하는 기존 접근과 달리, 연속된 값을 가지는 해빙 농도의 확률 분포를 학습함으로써 보다 안정적이고 일관된 예측을 가능하게 한다.


2.1 Diffusion Transformer 적용

해빙 농도는 각 픽셀이 연속적인 값을 가지는 물리량으로 정의되며, 이러한 특성은 미래 상태를 확률 분포로 학습하는 생성적 접근에 적합하다. 본 연구에서는 해빙 농도의 예측 문제를 연속된 값의 분포 추정 문제로 정의한다.

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \varepsilon, \quad \varepsilon \sim \text{Gaussian}(0, I) \quad (1)$$

x_0 는 원본 이미지, α_t 는 원본 이미지 보존율, ε 는 노이즈로 수식 (1)과 같이 정의한다. 가우시안 분포 형태를 가진 잡음을 점진적으로 추가한 뒤 잡음을 예측하는 Diffusion 기반 생성 방식을 적용하였다[6]. Diffusion 방식은 잡음이 주입된 상태에서 입력 조건을 반영하여 잡음을 예측하도록 학습한다. 이 과정을 통해 특정 조건을 반영한 데이터 분포를 안정적으로 근사할 수 있으며, 이는 각 픽셀이 연속적인 값을 갖는 해빙 농도의 통계적 특성을 충분히 반영한다[7].

공간적 패턴의 전역적 상관관계를 효과적으로 학습하기 위하여 본 연구에서는 해빙 농도 데이터를 16×16 크기의 패치 단위로 분할한다. 그림 2는 16×16 패치화가 적용된 448×304 해빙 농도 상태를 나타낸다. 패치화 된 해빙 농도

그림 2. 16×16 패치화 된 해빙 농도 상태

2.2 적응적 계층 정규화를 통한 환경 정보 주입

해빙 농도의 변화는 기후 환경과 이전 시점의 해빙 상태에 강하게 의존하는 시공간적 관계를 가진다. 동일한 상태라 하더라도 조건에 따라 상이한 변화 양상을 보일 수 있다. 따라서, 미래 해빙 농도를 생성하기 위해서는 이러한 조건

표 1. 24개월 예측 시 월별 해빙 농도 RMSE 비교 (%)

구분	1월	2월	3월	4월	5월	6월	7월	8월	9월	10월	11월	12월	연평균
2023년	7.7	10.7	12.0	10.9	11.1	14.2	15.4	17.6	19.0	18.5	13.1	14.3	13.7
2024년	13.1	14.6	14.0	13.3	13.0	16.9	15.4	16.2	16.9	17.4	10.8	12.9	14.6

정보가 모델의 내부 표현에 직접적으로 반영될 필요가 있다. 본 연구에서 기후 정보와 이전 시점의 해빙 상태를 Diffusion 모델에 효과적으로 주입하기 위해 적응적 계층 정규화를 사용한다. 외부 조건 정보를 통해 패치화 된 잡음의 정규화 계층에서 스케일과 시프트를 조절함으로써, 조건 정보가 은닉 특징의 분포를 직접적으로 제어할 수 있도록 한다. h 는 추출한 특징, c 는 조건 정보로 수식 (2), (3)과 같이 정의한다:

$$\text{adaLN}(h, c) = \gamma(c) \odot \text{LN}(h) + \beta(c) \quad (2)$$

$$[\gamma(c), \beta(c)] = \text{MLP}(c) \quad (3)$$

정규화 과정은 조건 정보를 단순히 입력으로 결합하는 방식에 비하여, 잡음 제거 과정 전반에 걸쳐 조건 입력을 안정적으로 반영할 수 있다는 장점을 가진다[8]. 적응형 계층 정규화 방식을 통해 Diffusion 모델에서 반복적으로 수행되는 잡음 예측 단계마다 기후 환경 농도에 대한 조건 정보가 잡음화 된 해빙 농도에 일관되게 반영되도록 한다. 결과적으로 시간적 일관성과 높은 물리적 개연성을 갖는 해빙 농도 생성을 가능하게 한다.

2.3 장기간 생성 품질 향상을 위한 자기회귀 미세 조정 학습

본 연구에서는 자기회귀 방식의 영상 생성 구조로 예측 과정을 구성한다[9]. 그림 3은 자기회귀 생성 과정을 나타낸다. 자기회귀 방식은 이전 시점의 생성된 이미지가 다음 시점의 입력으로 사용되는 구조를 의미한다. 영상 생성 구조는 날짜 별 연속 예측을 가능하게 한다는 장점을 가지지만, 모델이 생성한 출력이 다시 조건 정보로 사용되는 과정에서 작은 예측 오차가 반복적으로 누적되어 장기 생성 시 오차가 증폭될 수 있다[10]. 특히, 초기 시점에서 발생한 방향성 오차는 해빙 경계와 같이 민감한 공간 영역에서 더욱 쉽게 발생하여 실제 물리적 변화 양상과 다른 방향으로 예측이 진행되는 편향과 오차 누적이 유발될 가능성이 존재한다. 이러한 오차 누적 문제는 예측 시간이 길어질수록 점진적으로 강화되어, 장기 생성 안정성을 저해하는 주요 요인으로 작용한다.

자기 회귀 생성 구조의 오차 누적 문제를 완화하기 위하여 본 연구에서는 미세 조정 학습을 진행하였다. 미세 조정 학습은 일정 길이의 예측을 진행한 뒤, 예측된 기간 전체에 대한 오차를

사용하여 추가 학습하는 방식으로 진행하였다. 미세 조정 학습을 진행함으로써 영상 생성 구조의 모델이 장거리 예측 시에도 충분한 안정성을 확보하였다. 이 과정은 학습 시 관측된 분포와 추론 시 노출되는 분포 간의 불일치로 인해 발생하는




그림 3. 자기회귀 생성 프레임워크

누적 오차를 직접적으로 다루며, 장기 예측 시 잘못된 방향 제어를 억제하는 역할을 한다.

본 연구에서는 일주일 Roll-out 기반으로 오차를 재구성하여 미세 조정 학습을 수행하였다.

$$Loss = \frac{1}{M} \sum_{k=1}^M (\hat{y}_{t+k} - y_{t+k})^2 \quad (4)$$

미세 조정 방식은 수식(4)과 같이 정의된다. 자기회귀 방식의 생성을 통하여 $M=7$ 로 설정하여 7일의 해빙 상태를 생성하고 이에 대한 평균 오차를 통하여 미세 조정 학습을 진행하였다. 짧은 구간에서 발생하는 오차 누적 및 방향성 오차 특성을 모델이 명시적으로 학습하도록 하였다. 이를 통해 장기 생성 시 예측의 시간적 일관성을 유지하면서도, 누적 오차로 인한 편향이 특정 방향으로 고착되어 증폭되는 현상을 효과적으로 완화할 수 있음을 확인하였다.

3. 실험

본 연구에서는 북극 해빙의 정확한 예측을 위하여 NOAA[11]에서 제공하는 위성 기반 북극 해빙 농도 데이터를 학습에 사용하였다. 2011년부터 2022년까지의 관측 자료를 사용하였으며, 해당 데이터의 육지 부분 Masking을 위하여 빙하 농도가 NaN으로 표시된 영역을 이용하여 육지에 대한 Masking을 진행하였다. 또한

표 2. 자기회귀 미세조정 전·후 장기예측(2024년) RMSE 비교 (%)

구분	1월	2월	3월	4월	5월	6월	7월	8월	9월	10월	11월	12월	연평균
미세조정 전	12.6	13.7	12.6	13.6	13.8	17.8	18.4	19.1	17.8	18.1	12.9	12.8	15.3
미세조정 후	13.1	14.6	14.0	13.3	13.0	16.9	15.4	16.2	16.9	17.4	10.8	12.9	14.6




그림 4. 정성적 평가 결과 (왼쪽: 예측, 중간: 실제 해빙 상태, 오른쪽: 오차)

환경조건 데이터를 학습에 사용하기 위해 Climate Data Store의 ERA5-Land hourly data[12]를 사용하였으며 2011년에서 2022년까지 데이터를 학습에 포함하였다. 실험을 위해서 환경은 Ubuntu 20.04 운영체제와 GPU는 RTX A6000을 사용하였고 Epoch 150, Batch size 30으로 설정하여, 학습을 수행하였다.

Diffusion Transformer를 이용한 프레임워크의 예측 성능은, 학습에 사용되지 않은 2023년과 2024년을 대상으로 평가하였으며, 정량적 지표로는 RMSE(%) 지표를 사용하였다.

3.1 실험 결과 평가 및 분석

표 1은 2023년과 2024년 월별 성능 평가결과를

나타낸다. 정량적 실험 결과, 본 연구의 모델은 2023년 1월부터 2024년 12월 31일까지 2년간 빙하 농도 변화 양상을 생성하였다. 2024년에 대한 빙하 농도 예측 결과는 연 평균 14.6%의 RMSE를 기록하였다. 특히 빙하 변동성이 불규칙한 여름 기간에 대해서도 RMSE값이 폭주하지 않고, 안정적으로 유지됨을 확인할 수 있다.

2023년 실험 결과는 생성 시작 시점과 가까운 기간에 대해서는 최저 7.7%의 월 평균 RMSE 값을 보였으며, 이는 단기간 예측에서 모델이 높은 예측 정확도를 가지며 장기 예측 시에도 RMSE 값이 안정적으로 유지되었다

그림 4의 왼쪽 사진은 본 연구에서 개발한 모델이 예측한 빙하 농도 결과를 시각화한 것이다. 여기서 좌측단에 위치한 예측결과는 모델이 생성 시작 시점과 가까운 기간에 대한 결과이며, 기존 실제 해빙 농도와 오차를 시각화 하였을 때(우측단) 매우 유사하게 예측되었음을 확인할 수 있다.

그림 4의 장기 예측 결과(3월 좌측)는 2024년 11월 18일에 대한 예측 결과이다. 오차 결과를 시각화 하였을 때, 빙하의 가장자리에 대한 오차가 발생하였지만 대부분의 빙하에 대해서는 예측 정확도가 높음을 보인다.

3.2 절제 연구

자기회귀 미세 조정을 통해 생성 모델에서 발생하는 오차 누적에 대한 억제 효과를 검증하기 위해, 본 연구에서는 자기회귀 미세 조정 적용 전·후의 장기 예측 성능을 비교하는 실험을 수행하였다. 표 2는 장기 예측 미세 조정 적용 전·후 결과를 나타낸다. 2024년 8월부터 11월까지의 예측 구간에서 RMSE 기준으로 약 1%에서 3% 수준의 성능 향상이 확인되었다. RMSE의 유의미한 감소는, 제안한 방법이 장기 예측 과정에서 누적되는 오차를 효과적으로 완화할 수 있음을 시사한다.

1월에서 3월 그리고 12월의 RMSE가 상승했음을 확인할 수 있다. 해당 월은 빙하의 변동성이 가장 작은 겨울철 빙하의 농도를 나타내는데, 학습 데이터에 대하여 미세 조정 과정에서 과적합이 발생하여 오히려 검증 데이터셋에 대해서 성능이 낮아짐으로 추정할 수 있다.

4. 결론

본 연구에서는 Diffusion Transformer 방식,

적응형 계층 정규화, 장기 생성을 위한 자기회귀 미세 조정 학습전략을 결합하여, 장기간 그리고 여름철 같이 변동성이 큰 기간에서도 안정적인 해빙농도 예측이 가능함을 확인하였다. 이를 통해 해빙농도 예측에서 영상 생성 모델, 특히 Diffusion 기반 생성 모델이 장기간 예측 문제에도 효과적으로 적용될 수 있음을 시사하며, 향후 해빙 예측에서 확장되어 다양한 지구환경 영상 예측 분야에서의 적용 가능성을 제시한다.

참고문헌

- [1] J. C. Stroeve, M. C. Serreze, M. M. Holland, J. E. Kay, J. Malanik, and A. P. Barrett, "The Arctic's rapidly shrinking sea ice cover: a research synthesis," *Climatic Change*, vol. 110, no. 3–4, pp. 1005–1027, 2012.
- [2] J. Chi and H.-C. Kim, "Prediction of Arctic Sea Ice Concentration Using a Fully Data Driven Deep Neural Network," *Remote Sensing*, vol. 9, no. 12, p. 1305, 2017.
- [3] Y. J. Kim, H. Kim, D. Han, J. C. Stroeve, and J. Im, "Long-term prediction of Arctic sea ice concentrations using deep learning: Effects of surface temperature, radiation, and wind conditions," *Remote Sensing of Environment*, 2025.
- [4] D. Notz and J. Stroeve, "The trajectory of the Arctic sea ice cover," *Science*, vol. 354, no. 6312, pp. 747–750, 2016.
- [5] T. Chi, H. Kim, and J. Im, "Deep learning-based sea ice concentration forecasting," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 13, pp. 4620–4631, 2020.
- [6] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," *Advances in Neural Information Processing Systems*, vol. 33, pp. 6840–6851, 2020.
- [7] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, "Score-based generative modeling through stochastic differential equations," *International Conference on Learning Representations*, 2021.
- [8] W. Peebles and S. Xie, "Scalable diffusion models with transformers," *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4195–4205, 2023.
- [9] J. Ho, T. Salimans, A. Gritsenko, et al., "Video diffusion models," *Advances in Neural Information Processing Systems*, 2022.
- [10] S. Bengio, O. Vinyals, N. Jaitly, and N. Shazeer, "Scheduled sampling for sequence prediction with recurrent neural networks," *Advances in Neural Information Processing Systems*, pp. 1171–1179, 2015.
- [11] Meier, W. N., Fetterer, F., Windnagel, A. K., Stewart, J. S., & Stafford, T. (2024). NOAA/NSIDC Climate Data Record of Passive Microwave Sea Ice Concentration (G02202, Version 5) [Data set]. Boulder, Colorado USA: National Snow and Ice Data Center.[Internet] Available at: <https://nsidc.org/data/g02202/versions/5>
- [12] Copernicus Climate Change Service (C3S). (year) ERA5-Land hourly data from 1950 to present [Data set]. Copernicus Climate Change Service (C3S) Climate Data Store (CDS).DOI: 10.24381/cds.e2161bac Available at: <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land?tab=download>